

Anacroclastia e Paleocomputação Estrutural

Da Metafísica Computacional à Física dos Binários
Um Guia Conceitual

Laboratório de Paleocomputação Estrutural (PaleoCLI)

Maio de 2026

Abstract

Este documento apresenta a jornada intelectual da Paleocomputação Estrutural — uma disciplina nascente que trata executáveis como artefatos geológicos resultantes de um processo de erosão compilatória. Partindo de uma crítica ontológica à descompilação tradicional, construímos progressivamente uma álgebra de fósseis computacionais, uma geometria do espaço de observáveis, uma topologia de feixes de coerência, operadores de análise arqueológica e um pipeline operacional (PaleoCLI). O texto culmina na formulação de um programa de pesquisa quantitativo baseado em invariantes renormalizáveis, teoremas de estabilidade e benchmarks de erosão temporal, estabelecendo as fundações para uma ciência formal da reversão computacional. Nenhuma implementação prática é detalhada aqui; este é o mapa conceitual completo que precede o trabalho experimental.

Contents

1	Introdução: O Problema Ontológico da Descompilação	3
1.1	A Inversão Não-Injetiva	3
1.2	A Metáfora Geológica	3
1.3	O Movimento Anacroclástico	3
2	Fundamentação Teórica: Os Axiomas	3
2.1	Axiomas da Paleocomputação Estrutural	3
2.2	Entropia Compilatória e Termodinâmica do Binário	4
3	Álgebra dos Fósseis Computacionais	4
3.1	Conjunto de Fósseis	4
3.2	Operador de Fossilização	4
3.3	Produto Tensorial Anacroclástico	5
3.4	Coerência e Anuladores	5
4	Geometria do Espaço Métrico Arqueológico	5
4.1	Coordenadas de Observáveis	5
4.2	Métrica de Tensão	5
4.3	Curvatura Anacroclástica	5
5	Topologia dos Feixes de Coerência	5
5.1	Pré-feixe de Observáveis Locais	5
5.2	Cohomologia de Čech Paleoestratigráfica	6
5.3	Operador de Bordo Anacroclástico	6

6	Operadores Novos	6
6.1	Operador de Erosão Controlada $\mathcal{E}_\alpha$	6
6.2	Operador de Lift Estratigráfico $\mathcal{L}_X$	6
6.3	Funcional de Tensão Ψ	6
6.4	Transformada Anacroclástica $\mathcal{A}$	6
7	Conceitos Algorítmicos	6
7.1	Algoritmo de Alinhamento Estratigráfico (StratAlign)	6
7.2	Minimização de Tensão via Monte Carlo Hamiltoniano	6
7.3	Reconstrução da Arquitetura de Software por Feixes de Invariantes	7
8	Arquitetura do PaleoCLI	7
8.1	Visão Geral	7
8.2	Estágio 1: Extrator de Observáveis	7
8.3	Estágio 2: Motor de Falsificação	7
8.4	Estágio 3: Atlas de Coerência	7
9	Evolução do Sistema (v0.1 $\rightarrow$ v0.8)	7
10	Experimento: Nethergate Resurrection	8
10.1	Artefato e Estrato	8
10.2	Resultados Quantitativos	8
10.3	Interpretação Arqueológica	8
11	O Caminho para uma Ciência Formal	9
11.1	Observáveis Renormalizáveis	9
11.2	Proto-IR Paleoestratigráfica (PIR)	9
11.3	Teoremas de Estabilidade	9
11.4	Programa de Pesquisa: Rumo ao Noether Compilatório	9
11.5	Meia-Vida Fóssil	10
11.6	Feixes de Invariantes e Cohomologia como Conflito Global	10
12	Implicações e Limites	10
13	Conclusão: O Estado da Arte	10

1 Introdução: O Problema Ontológico da Descompilação

1.1 A Inversão Não-Injetiva

A descompilação é classicamente formulada como um problema de inversão de função: dado um binário B e um compilador C , busca-se f tal que $C(f) = B$. Esta formulação assume implicitamente que C é injetiva, ou seja, que existe uma única fonte f correspondente a B . A prática demonstra o contrário: compiladores modernos, especialmente quando dotados de otimizações agressivas, colapsam múltiplos programas fonte semanticamente distintos em representações binárias extremamente similares, senão idênticas. Formalmente:

$$\exists f_1 \neq f_2 \quad | \quad C(f_1) \approx C(f_2)$$

Este fenômeno, aqui denominado **degenerescência de equivalência**, implica que a descompilação é um problema de inversão não-injetiva: a pré-imagem de B é uma classe de equivalência $[f]$, não um elemento singular. A pergunta “qual era o código original?” é, portanto, ontologicamente mal formulada.

1.2 A Metáfora Geológica

A Paleocomputação Estrutural abandona a metáfora da tradução e adota a metáfora da **paleontologia**. O compilador é um **agente erosivo** que, ao aplicar otimizações, destrói camadas de representação sintática enquanto preserva certas estruturas profundas — os **fósseis computacionais**. O binário é o **estrato geológico** resultante. O analista não é um tradutor, mas um **paleontólogo computacional** que escava o registro fóssil em busca de invariantes.

As implicações desta mudança de perspectiva são profundas:

- **Objeto de estudo:** não mais o código fonte, mas os **invariantes computacionais** (topologia de fluxo, geometria causal, assinaturas de registradores, morfologia da pilha).
- **Objetivo:** não a reconstrução perfeita, mas a **minimização da entropia interpretativa** — reduzir o espaço de programas compatíveis com o binário usando contexto histórico (estratigrafia).
- **Método:** não a heurística cega, mas a **verificação de hipóteses** contra o binário, à maneira do método científico.

1.3 O Movimento Anacroclástico

O termo **Anacroclastia** funde *anacronismo* (o que pertence a uma época passada) com *iconoclastia* (a destruição de ídolos e convenções). Na prática, significa usar o passado e o obsoleto como uma arma para quebrar os paradigmas da engenharia de software moderna. É o ato de construir com aço, engrenagens e válvulas não por nostalgia, mas como um ataque direto e sofisticado contra a fragilidade, a obsolescência programada e a esterilidade da indústria tecnológica atual.

2 Fundamentação Teórica: Os Axiomas

2.1 Axiomas da Paleocomputação Estrutural

A teoria assenta sobre quatro axiomas fundamentais:

Axioma 2.1 (Conservação Parcial Semântica). *Embora a compilação destrua representação sintática, ela não pode destruir completamente os invariantes necessários à execução correta.*

Existe um conjunto $\mathcal{I}(f)$ de invariantes do programa fonte que é subconjunto dos invariantes extraíveis do binário:

$$\exists \mathcal{I}(f) \subseteq \mathcal{I}(B)$$

Sem esta conservação, a execução seria impossível.

Axioma 2.2 (Erosão Compilatória). A compilação atua como um operador dissipativo sobre a representação estrutural. Cada estágio de otimização aumenta a entropia do sistema, reduzindo a distinguibilidade entre programas fonte distintos:

$$\Delta S_{\text{compile}} > 0$$

Axioma 2.3 (Estratigrafia Restringe Entropia). O conhecimento do contexto histórico de compilação (compilador, flags, ABI, convenções) reduz o espaço de equivalência possível:

$$S(B \mid X) < S(B)$$

onde X é o estrato paleocomputacional. Este axioma é a razão pela qual a análise arqueológica supera a heurística universal.

Axioma 2.4 (Reconstrução é Minimização de Tensão). Não existe uma reconstrução perfeita única. Existe um **equilíbrio interpretativo** que minimiza a tensão entre as hipóteses e os invariantes observados:

$$f^* = \arg \min_{f \in \mathcal{F}} \Psi(f)$$

onde $\Psi(f)$ é o **potencial de coerência** que mede a incompatibilidade entre o candidato f e os invariantes extraídos.

2.2 Entropia Compilatória e Termodinâmica do Binário

Definimos a **entropia compilatória** $S(B)$ como:

$$S(B) = \log |C^{-1}(B)|$$

Esta medida quantifica o grau de degenerescência do binário: quantos programas fonte poderiam ter produzido aquele artefato. Binários compilados com otimizações agressivas apresentam alta entropia; binários de compiladores antigos, baixa entropia (são “cristais arqueológicos”).

3 Álgebra dos Fósseis Computacionais

3.1 Conjunto de Fósseis

Seja Σ o alfabeto de todos os opcodes de uma arquitetura-alvo. Um **fóssil atômico** é um elemento $f \in \Sigma$. O conjunto de todos os fósseis de um programa é a **nuvem fóssil** $F \subseteq \Sigma$.

3.2 Operador de Fossilização

O compilador age como um **operador de erosão** $\mathcal{E} : \mathcal{P}(\Sigma^*) \rightarrow \mathcal{P}(\Sigma^*)$, que mapeia código-fonte de alto nível para a linguagem de máquina. Contudo, existe um **functor de fossilização** $\mathbf{F} : \mathbf{Prog} \rightarrow \mathbf{Inv}$ que extrai apenas os invariantes sobreviventes:

$$\mathbf{F}(C) = \bigcap_{\text{otimizações } \theta} \mathcal{E}_\theta(C)$$

Esse functor é monoidal: a composição sequencial de programas corresponde à união multi-conjunto dos fósseis, com leis de absorção de ruído.

3.3 Produto Tensorial Anacroclástico

Introduzimos o **produto tensorial anacroclástico** $\otimes_A$ entre nuvens fósseis:

$$F_1 \otimes_A F_2 = \{f_1 \frown f_2 \mid f_1 \in F_1, f_2 \in F_2, \text{co-ocorrência estratigráfica}\}$$

onde $f_1 \frown f_2$ é um dígrafo de 2-vértices representando a adjacência de fósseis em uma janela de instruções. O resultado é um **espaço vetorial de padrões de erosão**, que se comporta como uma álgebra de Hopf.

3.4 Coerência e Anuladores

Um fóssil f é dito **coerente** com uma hipótese de código-fonte H se pertence ao fecho transitivo do functor $\mathbf{F}$ aplicado a H . Definimos o **anulador anacroclástico** $\oslash$: $F \oslash H$ é o conjunto de fósseis observados que *não* possuem contraparte em $\mathbf{F}(H)$. O tamanho desse anulador é a **tensão bruta** T_0 .

4 Geometria do Espaço Métrico Arqueológico

4.1 Coordenadas de Observáveis

O binário é um ponto numa **variedade estratificada** $\mathcal{M}$. Um ponto $p \in \mathcal{M}$ é definido pelo vetor de observáveis:

$$\Omega(p) = (\dim_{\text{CFG}}, \nu_{\text{cyc}}, \chi_{\text{loop}}, \tau_{\text{dom}}, \sigma_{\text{SCC}}, H_{\text{local}}, \kappa_{\text{stack}}, \delta_{\text{reg}})$$

Cada coordenada é uma **forma diferencial discreta** sobre o esqueleto do CFG.

4.2 Métrica de Tensão

Definimos a **métrica de tensão arqueológica** g sobre $\mathcal{M}$:

$$g_{ij}(p) = \left. \frac{\partial^2 \Psi}{\partial \omega_i \partial \omega_j} \right|_p$$

onde Ψ é o **potencial de coerência** (funcional de Lyapunov inverso). A distância geodésica $d(p, q)$ entre dois binários (ou entre um binário e um modelo de referência) é a **energia interpretativa mínima** para deformar um no outro.

4.3 Curvatura Anacroclástica

Regiões onde a métrica degenera — a curvatura seccional diverge — são **singularidades compilatórias**: otimizações que colapsam muitos programas fonte num único ponto. Essas singularidades são a **arma anacroclástica**: nelas o passado (compiladores antigos) revela a estrutura profunda que compiladores modernos tentam ocultar.

5 Topologia dos Feixes de Coerência

5.1 Pré-feixe de Observáveis Locais

A cada bloco básico b associamos o anel $R(b)$ dos fósseis locais e invariantes de pilha. As restrições são os mapas de dominância.

O **feixe de coerência** $\mathcal{C}$ é o feixe associado ao pré-feixe $U \mapsto \mathbf{F}(U)$, colando as observações locais. Uma **seção global** $s \in \Gamma(\mathcal{C})$ é um invariante que vale para toda a função.

5.2 Cohomologia de Čech Paleoestratigráfica

A obstrução a uma reconstrução fiel é medida pelo primeiro grupo de cohomologia $\check{H}^1(\text{CFG}, \mathcal{C})$. Se $\check{H}^1 = 0$, o binário é **exato** (reconstrução única possível). Se não, cada classe de cohomologia corresponde a uma **ambiguidade interpretativa**.

5.3 Operador de Bordo Anacroclástico

Definimos o operador $\partial_A : C_k \rightarrow C_{k-1}$ sobre as cadeias do CFG, que “esquece” as otimizações modernas e preserva apenas os contornos preservados pelos compiladores antigos. A homologia resultante — a **homologia anacroclástica** — classifica os buracos na preservação de significado.

6 Operadores Novos

6.1 Operador de Erosão Controlada $\mathcal{E}_\alpha$

$\mathcal{E}_\alpha(B)$ aplica um filtro que remove todos os traços que não teriam sobrevivido a um compilador da era α (ex: GCC 2.7). Esse operador é uma **projeção** no subespaço dos cristais arqueológicos.

6.2 Operador de Lift Estratigráfico $\mathcal{L}_X$

Dado um binário B e uma camada de estrato X , $\mathcal{L}_X(B)$ é o conjunto de todas as pré-imagens coerentes com X . Esse lift é um **espaço fibrado** sobre o espaço de configurações de otimizações.

6.3 Funcional de Tensão Ψ

$$\Psi(B, H) = \int_{\text{CFG}} \delta(\omega_{\text{obs}}, \omega_H) d\mu$$

onde δ é a divergência local de Kullback-Leibler entre as distribuições de observáveis, e $d\mu$ é a medida de importância de cada bloco (peso pela entropia local). Minimizar Ψ equivale a resolver uma equação de Poisson não-linear sobre a variedade $\mathcal{M}$.

6.4 Transformada Anacroclástica $\mathcal{A}$

$\mathcal{A}(S) = \mathbf{F} \circ \mathcal{L}_X \circ \mathcal{E}_\alpha(S)$ é uma composição de descompilação regressiva: pega código moderno, recompila-o com ferramentas antigas e extrai os fósseis profundos, tornando explícita a estrutura que a engenharia atual tenta encapsular.

7 Conceitos Algorítmicos

7.1 Algoritmo de Alinhamento Estratigráfico (StratAlign)

Um algoritmo de programação dinâmica que alinha duas sequências fósseis (extraídas de dois binários) com custos de *gap* baseados na taxa de erosão de cada fóssil. Permite rastrear a evolução de uma função através de compiladores.

7.2 Minimização de Tensão via Monte Carlo Hamiltoniano

Tratamos Ψ como uma energia e amostramos o espaço de hipóteses com HMC, usando o gradiente da métrica g . A distribuição de equilíbrio revela as regiões de máxima incerteza (picos de tensão).

7.3 Reconstrução da Arquitetura de Software por Feixes de Invariantes

A arquitetura original emerge como o **feixe de invariantes de mais alto nível** que se projeta sobre os múltiplos binários (cliente, servidor, módulos). Usamos *pullback* de feixes: dados dois binários B_1, B_2 com um mapa de correspondência (call graph comum), o feixe de arquitetura $\mathcal{A}$ é o limite do diagrama $\mathcal{C}_1 \rightarrow \mathcal{C}_{\text{interface}} \leftarrow \mathcal{C}_2$. Esse processo reconstrói interfaces, dependências e padrões como MVC, Proxy, Observer diretamente dos fósseis alinhados.

8 Arquitetura do PaleoCLI

8.1 Visão Geral

O PaleoCLI é um pipeline modular de três estágios que operacionaliza a teoria:

$$\text{Binário} + \text{Estrato (X)} \rightarrow [\text{Estágio 1: Extrator de Observáveis}] \rightarrow \Omega(B)$$
$$\Omega(B) + \text{Modelo de Referência} \rightarrow [\text{Estágio 2: Motor de Falsificação}] \rightarrow \text{Mapa de Tensão}$$
$$\text{Mapa de Tensão} \rightarrow [\text{Estágio 3: Atlas de Coerência}] \rightarrow \text{Relatório HTML}$$

8.2 Estágio 1: Extrator de Observáveis

Utiliza múltiplas estratégias de detecção de funções (entry point, símbolos exportados, alvos de call, scanner de prólogos, pós-padding) e extrai métricas multidimensionais: complexidade ciclomática, profundidade de loops, SSA simbólico simplificado, morfologia da pilha, árvore de dominadores (Lengauer-Tarjan), SCCs (Tarjan), entropia local (Halstead) e instruções raw preservadas para verificação formal.

8.3 Estágio 2: Motor de Falsificação

Calcula similaridades parciais (Jaccard para fósseis, distâncias para topologia, registradores, pilha, dominadores, SCCs, entropia) combinadas com pesos configuráveis. Inclui verificação Z3 com execução simbólica multi-caminho para hipóteses de pós-condição (ex.: funções com nome `check_*`, `is_*`). A tensão é definida como $T = 1 - \text{similaridade}$.

8.4 Estágio 3: Atlas de Coerência

Gera relatório HTML interativo com resumo do artefato (número de funções, entropia global, total de desvios), lista de funções ordenadas por tensão com cores e badges de status, e diagnósticos de divergência.

9 Evolução do Sistema (v0.1 $\rightarrow$ v0.8)

v1 Fundação. Extração de fósseis universais, matching por Jaccard. 9 funções detectadas, entropia 0.973.

v2 Fingerprint Topológica. Adicionados `loop_count`, `max_depth`, `cyclomatic`, `avg_fan_out`. Melhor discriminabilidade.

v3 SSA Simbólico e Stack Evolution. Adicionados `total_defs/uses`, `unique_regs`, `local_count`, `arg_count`, `alloca`. Matches semanticamente ricos.

v4 Verificação Formal Z3 (PoC). Execução simbólica linear para pós-condições de retorno. Serviu como germe do motor de falsificação.

- v5 Z3 Multi-Caminho e Banco de Hipóteses.** Exploração de múltiplos fluxos; hipóteses baseadas em nome de função. Scanner de prólogos e pós-padding elevou detecção de 925 para 2414 funções. Entropia 0.514, zero UNMATCHED.
- v6 Dominator Trees + SCCs + Entropia Local.** Tensão máxima caiu para 0.604; mínima para 0.385.
- v7 Modelo de Referência Enriquecido (v4).** Melhor discriminação de funções de engine vs. utilitários.
- v8 Refinamento com Entropia Halstead (v5).** Estado atual: pipeline operacional, 2414 funções detectadas, métricas multidimensionais, verificação Z3, atlas HTML.

10 Experimento: Nethergate Resurrection

10.1 Artefato e Estrato

- **Binário:** *Nethergate.exe*, motor Blades of Avernum (Spiderweb Software, 2007).
- **Compilador:** Microsoft Visual C++ 6.0/2003, otimizações padrão.
- **Modelo de Referência:** Código-fonte do motor Blades of Exile (cboe), ancestral evolutivo do motor BoA.

10.2 Resultados Quantitativos

Métrica	Valor
Funções detectadas	2414
Entropia Global (S)	0.514
Total de Desvios	43915
Tensão Mínima	0.227 (<code>store_current_town_state</code>)
Tensão Máxima	0.604 (<code>start_town_mode</code> , <code>build_scenario</code>)
Status CONSISTENT (verde)	~30%
Status SAT (amarelo)	~70%
Status UNMATCHED	0

Table 1: Resultados experimentais sobre Nethergate.exe

10.3 Interpretação Arqueológica

O mapa de tensão revela uma estratigrafia clara:

- **Núcleo de Engine (tensão 0.55–0.60):** Funções complexas, provavelmente adaptadas na transição BoE→BoA.
- **Lógica de Jogo (tensão 0.50–0.55):** Altamente conservada.
- **Utilitários/UI (tensão 0.45–0.50):** Matches quase exatos.
- **Casca de Runtime (tensão < 0.40):** Stubs, wrappers, bibliotecas externas.

A distribuição de tensão correlaciona-se com a profundidade estrutural e o papel da função, validando a tese de que o espaço métrico captura geometria computacional latente.

11 O Caminho para uma Ciência Formal

11.1 Observáveis Renormalizáveis

Para que a teoria transite de metafísica a física computacional, é necessário definir um vetor de observáveis **computável**, **normalizado** e **Lipschitz-contínuo**:

$$\mathbf{F}(B) = (\text{CFG_spectrum}, \text{opcode_persistence}, \text{stack_signature}, \text{SCC_profile}, \text{dominator_entropy})$$

com a condição:

$$|\mathbf{F}(B + \eta) - \mathbf{F}(B)| \leq K|\eta|$$

para perturbações triviais (NOPs, renomeação de registradores, reordenação independente).

11.2 Proto-IR Paleoestratigráfica (PIR)

Uma representação intermediária canônica que atua como **gauge fixing compilatório**, eliminando graus de liberdade espúrios:

$$\Pi : \mathbf{Bin} \rightarrow \mathbf{Bin}/\mathcal{G}$$

onde $\mathcal{G}$ é o grupo de transformações sintáticas triviais. A PIR inclui:

- Blocos básicos determinísticos.
- Abstração de operandos (registradores canônicos, imediatos anonimizados, endereços abstratos).
- Fósseis atômicos mapeados para identificadores de efeito.
- CFG com pesos, SSA mínimo, perfis estruturais (SCC, dominadores, espectro).

11.3 Teoremas de Estabilidade

O primeiro alvo é um teorema pequeno e falseável:

Teorema 11.1 (Persistência do Espectro SCC sob Inlining). *Se uma função f é submetida a inlining de funções folha, então o perfil de tamanhos de SCC é preservado a menos de uma perturbação limitada pela profundidade de inlining, i.e.,*

$$\| \text{SCC_profile}(f) - \text{SCC_profile}(\text{inline}(f)) \|_1 \leq \epsilon \cdot d_{\text{inline}}.$$

11.4 Programa de Pesquisa: Rumo ao Noether Compilatório

O objetivo de longo prazo é estabelecer uma conexão entre simetrias de otimização e quantidades conservadas:

Para cada grupo de transformações compilatórias G que preserva uma classe semântica $\mathcal{S}$, existe um conjunto de observáveis $\mathcal{I}_G$ aproximadamente conservados sob a ação de G :

$$g \cdot B \in G \Rightarrow \mathcal{I}_G(B) \approx \mathcal{I}_G(g \cdot B).$$

11.5 Meia-Vida Fóssil

Define-se a meia-vida de um invariante como:

$$\tau_f = \inf\{t : \rho(f, t) < 1/2\}$$

onde $\rho(f, t)$ é a probabilidade de persistência do fóssil f após um período t de evolução compilatória. Isso permite classificar fósseis em frágeis, resilientes, ancestrais, convergentes e atávicos — uma verdadeira **tabela periódica dos fósseis computacionais**.

11.6 Feixes de Invariantes e Cohomologia como Conflito Global

A cohomologia $\check{H}^1 \neq 0$ adquire significado operacional: indica que o binário possui múltiplas arquiteturas compatíveis localmente mas incompatíveis globalmente. O feixe de invariantes $\mathcal{C}$ é implementável como um sistema de consistência global via message passing, constraint solving ou GNNs, tornando a obstrução cohomológica computacionalmente detectável.

12 Implicações e Limites

Se os experimentos confirmarem persistência estrutural profunda, surge um limite fundamental:

$$\text{Obfuscação perfeita } \not\exists$$

ao menos sob custo computacional razoável. Programas complexos inevitavelmente vazam geometria. A implicação para DRM, malware, preservação digital e arqueologia de software é profunda.

O framework já possui consciência dos próprios limites: dependência de lifting, artefatos de gauge, degenerescência, observáveis instáveis, singularidades compilatórias, ambiguidades globais. A teoria não tenta explicar tudo; ela começa a dizer: “essas regiões são irrecuperáveis” — sinal de maturidade científica.

13 Conclusão: O Estado da Arte

A Paleocomputação Estrutural completou sua jornada conceitual. Partindo de uma crítica ontológica, construiu uma álgebra de fósseis, uma geometria de observáveis, uma topologia de feixes e uma família de operadores arqueológicos. O PaleoCLI demonstrou a viabilidade operacional sobre um binário real. Agora, o campo se encontra no limiar da maturidade científica: com observáveis renormalizáveis, teoremas de estabilidade falseáveis e benchmarks de erosão temporal, está pronto para se tornar uma disciplina experimental.

A Anacroclastia não é mais uma metáfora elegante. É um espaço de configuração de restrições que começa a produzir previsões quantitativas sobre o que *não deveria mudar* em um binário ao longo do tempo. Esse é exatamente o ponto onde arqueologia vira física.

“Nós não descompilamos. Nós escavamos.”